

Caracterizando a Atividade de Code Review no GitHub

Gabriel Ramos Ferreira, João Pedro Silva Braga

09 de outubro de 2025

1 Introdução

A prática de *code review*, ou revisão de código, consolidou-se como um **pilar fundamental nos processos de desenvolvimento de software modernos**, especialmente em metodologias ágeis. Ela consiste na inspeção sistemática do código-fonte por desenvolvedores que não sejam o autor original, com o objetivo de identificar defeitos, garantir a conformidade com padrões de codificação e melhorar a qualidade geral do software antes de sua integração à base de código principal.

No ecossistema de desenvolvimento de software de código aberto (open source), plataformas como o GitHub potencializaram essa prática através do mecanismo de *Pull Requests* (PRs). Um PR formaliza uma proposta de contribuição, que é então avaliada, discutida e, por fim, aceita (merged) ou rejeitada (closed) por mantenedores do projeto. Compreender os fatores que influenciam o destino de um PR e o esforço de revisão despendido é crucial para otimizar a colaboração e a eficiência em projetos de larga escala.

Neste contexto, este estudo se propõe a **caracterizar a atividade de code review** em repositórios populares do GitHub, analisando a relação entre as características de um PR e dois desfechos principais: seu status final (aceito ou rejeitado) e o número de revisões que ele recebe.

1.1 Objetivo Geral

O objetivo geral deste trabalho é analisar a atividade de code review em repositórios populares do GitHub, buscando identificar e caracterizar as variáveis que influenciam no resultado final de um Pull Request (seja ele aceito ou rejeitado), bem como no número de revisões que ele recebe.

1.2 Objetivos Específicos e Questões de Pesquisa

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos, que correspondem diretamente às questões de pesquisa (RQs) do estudo:

- **RQ01:** Investigar a relação entre o tamanho dos PRs e o seu feedback final.
- **RQ02:** Investigar a relação entre o tempo de análise dos PRs e o seu feedback final.
- **RQ03:** Investigar a relação entre a descrição dos PRs e o seu feedback final.
- **RQ04:** Investigar a relação entre as interações nos PRs e o seu feedback final.
- **RQ05:** Investigar a relação entre o tamanho dos PRs e o número de revisões realizadas.

- **RQ06:** Investigar a relação entre o tempo de análise dos PRs e o número de revisões realizadas.
- **RQ07:** Investigar a relação entre a descrição dos PRs e o número de revisões realizadas.
- **RQ08:** Investigar a relação entre as interações nos PRs e o número de revisões realizadas.

1.3 Hipóteses

Para cada questão de pesquisa, foram formuladas uma hipótese nula (H_0), que postula a ausência de relação entre as variáveis, e uma hipótese alternativa (H_1), que sugere a existência de tal relação.

Dimensão A: Feedback Final das Revisões (Status do PR)

RQ01: Tamanho vs. Feedback Final H_0 : Não existe relação estatisticamente significativa entre o tamanho de um PR (linhas de código alteradas, número de arquivos) e seu status final (aceito ou rejeitado).

H_1 : Existe uma relação estatisticamente significativa entre o tamanho de um PR e seu status final.

RQ02: Tempo de Análise vs. Feedback Final H_0 : Não existe relação entre o tempo de análise de um PR e seu status final.

H_2 : Existe uma relação entre o tempo de análise de um PR e seu status final.

RQ03: Descrição vs. Feedback Final H_0 : Não existe relação entre o tamanho da descrição de um PR e seu status final.

H_3 : Existe uma relação entre o tamanho da descrição de um PR e seu status final.

RQ04: Interações vs. Feedback Final H_0 : Não existe relação entre o número de interações (comentários, participantes) em um PR e seu status final.

H_4 : Existe uma relação entre o número de interações em um PR e seu status final.

Dimensão B: Número de Revisões

RQ05: Tamanho vs. Número de Revisões H_0 : Não existe correlação entre o tamanho de um PR e o número de revisões que ele recebe.

H_5 : Existe uma correlação entre o tamanho de um PR e o número de revisões que ele recebe.

RQ06: Tempo de Análise vs. Número de Revisões H_0 : Não existe correlação entre o tempo de análise de um PR e o número de revisões que ele recebe.

H_6 : Existe uma correlação entre o tempo de análise de um PR e o número de revisões que ele recebe.

RQ07: Descrição vs. Número de Revisões H_0 : Não existe correlação entre o tamanho da descrição de um PR e o número de revisões que ele recebe.

H_7 : Existe uma correlação entre o tamanho da descrição de um PR e o número de revisões que ele recebe.

RQ08: Interações vs. Número de Revisões H_0 : Não existe correlação entre o número de interações em um PR e o número de revisões que ele recebe.

H_8 : Existe uma correlação entre o número de interações em um PR e o número de revisões que ele recebe.

1.4 Estrutura do Relatório

Este relatório está organizado da seguinte forma. A Seção 2 detalha a **Metodologia** empregada, incluindo o processo de coleta e filtragem de dados, a definição das variáveis e os métodos de análise estatística. A Seção 3 apresenta os **Resultados** obtidos, primeiro com uma análise descritiva do dataset e, em seguida, respondendo a cada uma das questões de pesquisa com dados e visualizações. Finalmente, a Seção 4 apresenta a **Discussão e Conclusão**, onde os resultados são interpretados, as limitações do estudo são abordadas e direções para trabalhos futuros são sugeridas.

2 Metodologia

Para responder às questões de pesquisa propostas, foi conduzida **uma pesquisa empírica de caráter quantitativo e observacional**. A abordagem metodológica adotada segue as etapas fundamentais da experimentação em Engenharia de Software, que envolve a definição do problema, coleta de dados, análise e interpretação dos resultados.

Este estudo se enquadra como uma **pesquisa observacional**, pois analisa dados históricos extraídos de repositórios de software sem manipular variáveis independentes, como ocorreria em um experimento controlado. O objetivo é, portanto, identificar correlações e caracterizar o fenômeno do *code review* em seu ambiente natural, a plataforma GitHub.

2.1 Procedimento de Coleta e Filtragem de Dados

A **construção do dataset** foi a primeira etapa executada e seguiu um processo rigoroso de seleção e filtragem para garantir a qualidade e a relevância dos dados. O procedimento foi dividido nas seguintes etapas:

1. **Seleção de Repositórios:** Foram selecionados os **200 repositórios** de software mais populares da plataforma GitHub, utilizando o número de estrelas como critério de popularidade. Esta escolha visa garantir que a análise seja realizada em projetos ativos, maduros e com um volume significativo de contribuições.
2. **Seleção de Pull Requests (PRs):** Para cada repositório selecionado, foram extraídos os PRs que atendiam aos seguintes critérios iniciais:
 - O repositório deveria possuir um mínimo de 100 PRs com status **MERGED** (aceito) ou **CLOSED** (rejeitado sem ser aceito).
 - Apenas PRs com status final **MERGED** ou **CLOSED** foram incluídos no dataset, excluindo-se aqueles ainda abertos (**OPEN**).
3. **Filtragem por Atividade de Revisão:** Com o objetivo de analisar exclusivamente os PRs que passaram por um processo de revisão humana, foram aplicados os seguintes filtros:
 - O PR deveria ter recebido pelo menos **uma revisão** formal.
 - Para mitigar a inclusão de revisões automáticas realizadas por *bots* ou ferramentas de Integração Contínua (CI/CD), foi estabelecido um critério temporal: apenas PRs cujo tempo entre a criação e a última atividade (merge ou close) fosse **maior que uma hora** foram mantidos. Este filtro parte da premissa de que revisões automáticas são tipicamente muito mais rápidas que as humanas.

2.2 Definição das Variáveis

As variáveis do estudo foram definidas com base nas métricas propostas no roteiro e classificadas como dependentes ou independentes para orientar a análise das questões de pesquisa.

2.2.1 Variáveis Dependentes

As variáveis dependentes são os resultados que buscamos explicar ou prever. Para este estudo, são duas:

Status Final do PR: Uma variável categórica que representa o desfecho da revisão. Assume os valores MERGED ou CLOSED. Esta variável é o foco das questões de pesquisa de RQ01 a RQ04.

Número de Revisões: Uma variável quantitativa discreta que representa o total de revisões formais recebidas por um PR. É o foco das questões de pesquisa de RQ05 a RQ08.

2.2.2 Variáveis Independentes

As variáveis independentes são as características dos PRs que podem influenciar as variáveis dependentes.

Tamanho: Métrica que quantifica a magnitude da mudança proposta no PR. É composta por:

- *Número de arquivos modificados;*
- *Total de linhas de código adicionadas e removidas.*

Tempo de Análise: Métrica que representa a duração do processo de revisão. É definida como o intervalo de tempo entre a data de criação do PR e a data de sua última atividade (merge ou close).

Descrição: Métrica que quantifica a qualidade da documentação do PR. É medida pelo *número de caracteres* no corpo da descrição do PR (em formato Markdown).

Interações: Métrica que captura o nível de comunicação e engajamento no PR. É composta por:

- *Número de participantes* (autor, revisores e outros colaboradores);
- *Número total de comentários.*

2.3 Procedimento de Análise dos Dados

Primeiramente, para cada questão de pesquisa, os dados foram sumarizados utilizando a **mediana** como medida de tendência central. A mediana foi escolhida em detrimento da média por ser uma medida mais robusta a valores extremos (*outliers*), que são comuns em dados de engenharia de software (e.g., um PR pode ter milhares de linhas alteradas, enquanto a maioria tem poucas).

Para a análise inferencial, que visa testar as hipóteses formuladas, foi empregado um **teste de correlação** para avaliar a força e a direção da associação entre as variáveis independentes e dependentes. O teste de correlação de Spearman (ou correlação de postos de Spearman) mede a força de uma relação monotônica (seja ela linear ou não) entre duas variáveis e é um teste não paramétrico, ou seja, não assume a normalidade dos dados.

A **Correlação de Spearman** foi escolhida para este estudo. A justificativa para essa escolha se baseia no fato de que as distribuições de métricas de software raramente são normais. Portanto, um teste não paramétrico como o de Spearman é mais adequado e confiável para analisar as relações propostas sem violar pressupostos estatísticos.

Os resultados do teste de Spearman geram um **coeficiente de correlação** (ρ , rho) que varia de -1 a +1. A interpretação da significância estatística foi baseada no valor-p, adotando um nível de significância (α) de 0.05. Relações com p-valor inferior a 0.05 foram consideradas estatisticamente significativas.

3 Resultados

Esta seção apresenta os resultados obtidos a partir da análise do dataset coletado. Inicialmente, é fornecida uma análise descritiva geral dos dados e, em seguida, os resultados são detalhados para cada uma das oito questões de pesquisa (RQs), divididas nas duas dimensões de estudo.

3.1 Análise Descritiva Geral

O dataset final é composto por **73.481 Pull Requests** que atenderam a todos os critérios de filtragem. A Figura 1 ilustra a distribuição desses PRs de acordo com seu status final.




Figura 1: Proporção de Pull Requests por status final.

Observa-se que 45.243 PRs (aproximadamente 61.6%) foram aceitos (**MERGED**), enquanto 28.238 (aproximadamente 38.4%) foram fechados sem serem integrados (**CLOSED**).

Adicionalmente, foi gerado um heatmap (Figura 2) para visualizar a correlação de Spearman entre todas as variáveis quantitativas do estudo. Este mapa fornece uma visão geral das relações que serão exploradas em detalhe nas RQs 05 a 08. As **correlações mais notáveis** são entre o tamanho do PR ('size-lines' e 'changed-files') e entre as métricas de interação ('participants-count-' e 'comments-count').




Figura 2: Heatmap de Correlação de Spearman entre as variáveis do estudo.

Dimensão A: Feedback Final das Revisões (Status do PR)

Para investigar a relação entre as características de um PR e seu status final, foi utilizado o **teste não paramétrico de Mann-Whitney U**, comparando as distribuições das métricas entre os grupos MERGED e CLOSED.

3.1.1 RQ01: Relação entre o tamanho dos PRs e o feedback final

Os boxplots na Figura 3.1.1 comparam a distribuição do tamanho dos PRs (em linhas e arquivos) para cada status. Visualmente, **PRs com status CLOSED tendem a ter uma distribuição de tamanho ligeiramente maior e mais dispersa.**




Figura 3: Boxplot do total de linhas por status.




Figura 4: Boxplot do número de arquivos por status.



A análise estatística confirma essa observação:

- **Total de Linhas:** A mediana de linhas para PRs MERGED foi de **28**, enquanto para PRs CLOSED foi de **35**. O teste de Mann-Whitney U indicou que essa **diferença** é estatisticamente **significativa** ($U = 6.05 \times 10^8$, $p < 0.001$).
- **Arquivos Alterados:** A mediana do número de arquivos foi idêntica para ambos os grupos (**2**). No entanto, a **diferença** nas distribuições foi considerada estatisticamente **significativa** ($U = 6.33 \times 10^8$, $p = 0.039$).

Com base nestes resultados, rejeita-se a hipótese nula H_{01} .

3.1.2 RQ02: Relação entre o tempo de análise e o feedback final

A Figura 3.1.2 apresenta duas visualizações para o tempo de análise. O boxplot (à esquerda) mostra que **PRs com status CLOSED** apresentam um **tempo de análise** medianamente **muito superior** aos PRs que são aceitos. O histograma (à direita) complementa essa visão, mostrando que a grande maioria dos PRs, especialmente os aceitos, são resolvidos em um curto período (próximo de zero), com uma longa cauda de PRs que demoram significativamente mais tempo.



A mediana do tempo de análise para PRs MERGED foi de **48.1 horas**, enquanto para PRs CLOSED foi de **122.4 horas**. O teste de Mann-Whitney U confirmou que essa diferença é **altamente significativa** ($U = 4.70 \times 10^8$, $p < 0.001$), levando à rejeição da hipótese nula H_{02} .

3.1.3 RQ03: Relação entre a descrição dos PRs e o feedback final

Analisando o tamanho da descrição, os resultados (Figura 5) indicam que PRs aceitos (MERGED) possuem, na mediana, descrições mais longas que os PRs rejeitados.




Figura 5: Boxplot do tamanho da descrição (em caracteres) por status.

A mediana do tamanho da descrição para PRs MERGED foi de **988 caracteres**, contra **872 caracteres** para PRs CLOSED. Essa diferença se mostrou estatisticamente significativa ($U = 7.24 \times 10^8$, $p < 0.001$). Portanto, a hipótese nula H_{03} é rejeitada.

3.1.4 RQ04: Relação entre as interações e o feedback final

As métricas de interação, número de participantes e comentários, também apresentaram diferenças significativas entre os grupos, como pode ser visto na Figura 3.1.4.





Figura 6: Número de participantes por status.

Figura 7: Número de comentários por status.

Em ambos os casos, PRs com status CLOSED apresentaram maior interação:

- **Participantes:** Mediana de **3** para MERGED e **4** para CLOSED. A diferença é estatisticamente significativa ($U = 5.40 \times 10^8$, $p < 0.001$).

- **Comentários:** Mediana de **2** para MERGED e **3** para CLOSED. A diferença também é estatisticamente significativa ($U = 4.84 \times 10^8$, $p < 0.001$).

Com isso, a hipótese nula H_{04} é rejeitada.

Dimensão B: Relação com o Número de Revisões

Para esta dimensão, foi utilizada a correlação de Spearman para medir a força e a direção da relação entre as métricas e o número de revisões (representado aqui pela métrica ‘participants-count’). A Tabela 1 resume os resultados. Todos os p-valores foram inferiores a 0.001, indicando significância estatística em todas as correlações.

Tabela 1: Resultados da Correlação de Spearman com o Número de Participantes.

Métrica (Variável Independente)	Coefficiente (ρ)	p-valor
RQ05: Tamanho (Linhas)	0.21	< 0.001
RQ05: Tamanho (Arquivos)	0.22	< 0.001
RQ06: Tempo de Análise	0.31	< 0.001
RQ07: Tamanho da Descrição	-0.06	< 0.001
RQ08: Número de Comentários	0.45	< 0.001




Figura 8: Tamanho (linhas) vs. Nº de Revisões




Figura 9: Tempo de Análise vs. Nº de Revisões




Figura 10: Descrição vs. Nº de Revisões




Figura 11: Comentários vs. Nº de Revisões

- **RQ05 (Tamanho):** Foi encontrada uma **correlação positiva fraca** entre o tamanho do PR e o número de revisões ($\rho = 0.21$ para linhas, $\rho = 0.22$ para arquivos). Isso sugere que PRs maiores tendem a envolver mais revisores, mas a relação não é forte. A hipótese nula H_{05} é rejeitada.
- **RQ06 (Tempo de Análise):** A **correlação** com o tempo de análise foi **positiva e fraca para moderada** ($\rho = 0.31$), indicando que PRs que levam mais tempo para serem analisados tendem a ter mais participantes. A hipótese nula H_{06} é rejeitada.
- **RQ07 (Descrição):** A análise revelou uma **correlação negativa muito fraca**, mas estatisticamente significativa ($\rho = -0.06$), entre o tamanho da descrição e o número de revisores. A hipótese nula H_{07} é rejeitada.
- **RQ08 (Comentários):** Esta foi a **correlação mais forte encontrada**. A relação entre o número de comentários e o número de participantes é positiva e moderada ($\rho = 0.45$), o que é esperado, já que **mais participantes tendem a gerar mais comentários**. A hipótese nula H_{08} é rejeitada.

4 Conclusão

Este capítulo final tem como objetivo interpretar os resultados apresentados, contextualizando-os com as hipóteses iniciais e a literatura existente. Além disso, são discutidas as limitações do estudo e propostas direções para trabalhos futuros, culminando em uma conclusão geral sobre a caracterização da atividade de code review no GitHub.

4.1 Discussão dos Resultados

A análise dos dados permitiu **rejeitar todas as hipóteses nulas**, indicando que as **características de um Pull Request** (tamanho, tempo, descrição e interações) possuem uma relação estatisticamente significativa tanto com seu **status final** quanto com o **número de revisões** que ele atrai.

4.1.1 Fatores que Influenciam a Aceitação de um PR (Dimensão A)

Os resultados da primeira dimensão pintam um retrato claro do que pode ser um PR "problemático". A nossa hipótese inicial era de que PRs maiores e com mais interações seriam mais propensos à rejeição. Os dados confirmam essa intuição:

- **Tamanho e Tempo de Análise (RQ01 e RQ02):** PRs fechados (CLOSED) são, na mediana, maiores e levam mais que o dobro do tempo para serem resolvidos. Isso sugere que **mudanças grandes e complexas** impõem uma **carga cognitiva elevada aos revisores**, gerando longas discussões que podem levar à estagnação e eventual abandono do PR. Este achado ecoa as preocupações levantadas por Fregnan et al. (2022) [1], que demonstram como fatores que aumentam a carga cognitiva, como a ordem dos arquivos, podem prejudicar a eficácia da revisão. Um PR excessivamente grande pode ser o principal fator de sobrecarga.
- **Descrição (RQ03):** Em contrapartida, PRs aceitos (MERGED) possuem descrições significativamente mais longas. A hipótese de que uma **boa documentação facilita a aprovação foi confirmada**. Uma descrição detalhada fornece o contexto necessário, esclarece a motivação da mudança e guia os revisores, reduzindo a ambiguidade e, consequentemente, o tempo e o atrito da revisão.
- **Interações (RQ04):** De forma que pode parecer contraintuitiva, um maior número de comentários e participantes está associado a PRs rejeitados. Isso indica que **"mais interação" não significa necessariamente "melhor interação"**. Um volume **elevado de comentários** pode ser um sintoma de **controvérsia**, confusão (potencialmente causada por uma descrição pobre), ou pedidos de refatoração extensiva que o autor original não consegue ou não deseja realizar.

4.1.2 Fatores que Influenciam o Esforço de Revisão (Dimensão B)

A segunda dimensão investigou o que atrai mais revisores para um PR.

- **Tamanho, Tempo e Comentários (RQ05, RQ06, RQ08):** Como esperado, PRs maiores, que **demoram mais e que geram mais comentários** também envolvem **mais pessoas**. As correlações, embora estatisticamente significativas, variam de fracas a moderadas. Isso indica que, embora essas métricas tenham influência, elas **não são os únicos determinantes do esforço de revisão**. A correlação mais forte foi entre comentários e participantes ($\rho = 0.45$), o que é natural, pois um gera o outro.

- **Descrição (RQ07):** O resultado mais surpreendente foi a correlação negativa, ainda que muito fraca, entre o tamanho da descrição e o número de participantes. Uma interpretação possível é que um PR com **uma descrição excepcionalmente clara e completa** pode ser tão autoexplicativo que um ou dois revisores principais **conseguem avaliá-lo e aprová-lo rapidamente**, sem a necessidade de consultar outros especialistas. A clareza da comunicação pode, portanto, otimizar o processo ao reduzir a necessidade de um quórum maior.

4.2 Limitações do Estudo

É importante reconhecer as limitações deste estudo:

- **Validade de Construto:** Nossas métricas são proxies. Por exemplo, ‘description-length’ é um proxy para a "qualidade da descrição", e ‘participants-count’ é um proxy para o "número de revisões". Um PR pode ter muitos participantes que não são revisores formais, e uma descrição longa não é necessariamente uma boa descrição.
- **Validade Interna:** Este é um estudo observacional baseado em correlações. **Não podemos afirmar causalidade.** Por exemplo, não podemos dizer que o longo tempo de análise **causa** a rejeição de um PR; é mais provável que ambos sejam sintomas de um problema subjacente de complexidade ou controvérsia.
- **Validade Externa:** Nossos resultados são baseados nos 200 repositórios mais populares do GitHub. Eles **podem não ser generalizáveis** para projetos menores, menos populares, privados ou de domínios específicos.

4.3 Trabalhos Futuros

Com base nos nossos achados e limitações, sugerimos as seguintes direções para pesquisas futuras:

1. **Análise Qualitativa de Comentários:** Investigar o **conteúdo** e o **sentimento** dos comentários em PRs aceitos versus rejeitados. Isso poderia confirmar nossa hipótese de que um alto volume de comentários em PRs rejeitados se deve a debates e sentimentos negativos. Um estudo como o de Rahman et al. (2025) [2], que classifica a polaridade dos comentários, seria um excelente ponto de partida para essa análise.
2. **Análise do Conteúdo da Descrição:** Ir além do comprimento da descrição e usar técnicas de Processamento de Linguagem Natural (PLN) para analisar a estrutura e a clareza das descrições, verificando se a presença de seções como "Motivação", "Implementação" e "Como Testar" se correlaciona com a aceitação do PR.
3. **Impacto de Ferramentas de Automação:** Nossos filtros tentaram remover revisões automáticas, mas o papel dos bots é cada vez mais proeminente. Um estudo focado, como o de Wessel et al. (2021) [3], poderia investigar como a presença de bots de code review afeta as métricas que analisamos, como o tempo de análise e o número de interações humanas.
4. **Replicação em Diferentes Contextos:** Replicar este estudo em um conjunto diferente de repositórios (e.g., projetos acadêmicos, corporativos ou de um ecossistema específico como Python/Data Science) para verificar a generalização dos achados.

4.4 Conclusão Geral

Este estudo caracterizou a atividade de code review em repositórios populares do GitHub, analisando a relação entre as propriedades de um Pull Request e seus resultados. Nossos achados demonstram que o sucesso de um PR está fortemente ligado à clareza da comunicação e à capacidade de gerenciar a complexidade. PRs com descrições detalhadas e escopo contido tendem a ser aceitos mais rapidamente. Em contraste, PRs grandes, que se arrastam no tempo e geram discussões volumosas, têm maior probabilidade de serem rejeitados.

Para desenvolvedores, a lição é clara: **investir tempo em escrever uma boa descrição e manter as mudanças pequenas e focadas é tão importante quanto escrever um bom código.** Para mantenedores de projetos, os resultados sugerem que PRs que permanecem abertos por muito tempo com alta interação podem ser "sinalizadores de risco", merecendo atenção para evitar a estagnação. Em suma, a comunicação e o gerenciamento da complexidade são pilares centrais para a saúde e a eficiência do desenvolvimento de software colaborativo moderno.

Referências

- [1] E. Fregnan, L. Braz, M. D'Ambros, G. Çalikli, and A. Bacchelli, "First Come First Served: The Impact of File Position on Code Review," *arXiv preprint arXiv:2203.11475*, 2022.
- [2] S. Rahman et al., "Measuring the effectiveness of code review comments in GitHub repositories: A machine learning approach," *arXiv preprint*, 2025.
- [3] M. Wessel, A. Serebrenik, I. Wiese, I. Steinmacher, and M. A. Gerosa, "Quality Gatekeepers: Investigating the Effects of Code Review Bots on Pull Request Activities," *arXiv preprint arXiv:2105.08316*, 2021.